Zadanie 5 Pracownia Specjalistyczna - Eksploracja danych

Krzysztof Funkowski

In [1]:
```
from math import *
import random
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import copy
```

Zadanie 5

Generator pseudolosowego zbioru danych na podstawie wielowymiarowego rozkładu normalnego z zadawaną strukturą macierzy kowariancji

Funkcja do generowania zbioru danych na podstawie wielowymiarowego rozkładu normalnego

Wyzhodzi zbiór, który przypomja formę chmury

In [2]:
```
def generate_dataset_norm(N):
    return np.column_stack((np.random.normal(0, 0.3, N), np.random.normal(0, 0.3, N)))
```

Funkcja do generowania zbioru danych wybierając dane z przedziału (0,1)

Wyzhodzi zbiór, który na wykresie przypmuje formę kwadratu

In [3]:
```
def generate_dataset_rand(N):
    dataset = []
    for _ in range(N):
        dataset.append([random.random(), random.random()])

    return dataset
```

Funkcja do rotacji zbiorem danych na podstawie podanego kątu

In [4]:
```
def rotate(phi):
    rad = np.radians(phi)
    rotation_arr = np.array([[np.cos(rad), np.sin(rad)],
                             [-np.sin(rad), np.cos(rad)]])

    return rotation_arr
```

Funkcja do rozciągania zbioru danych

In [5]:
```
def stretch(x, y):
    stretch_arr = np.array([[x, 0],
                            [0, y]])
    return stretch_arr
```

Funkcja do transformacji zbioru danych

In [10]:
```
def perform_transformation(dataset, rotation_angle, x, y):
    result_dataset = copy.deepcopy(dataset)

    stretching = stretch(x, y)
    result_dataset = np.dot(result_dataset, stretching)

    rotation = rotate(rotation_angle)
    result_dataset = np.dot(result_dataset, rotation)

    return result_dataset
```

Przypadek dla zbioru danych do testowania funkcji wybierając dane z przedziału (0,1) przy generowaniu dla osi pionowej i poziomej.

In [15]:
```
dataset = np.array(generate_dataset_rand(500))
```

In [39]:
```
plt.figure(figsize=(6, 6))

plt.scatter(dataset[:,0], dataset[:,1], color='red', marker='o')

plt.xlabel('X')
plt.ylabel('Y')

plt.xlim(-3, 3)
plt.ylim(-3, 3)

plt.title('Wygenerowany zbiór')
plt.show()
```

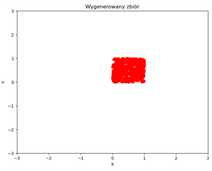

Test funkcji obrotu - Obrót o 45 stopni

In [21]:
```
ang45 = rotate(45)
ang45
```

Out[21]:
```
array([[ 0.70710678,  0.70710678],
       [-0.70710678,  0.70710678]])
```

In [22]:
```
dataset_ang45 = np.dot(dataset, ang45)
```

In [23]:
```
plt.figure(figsize=(6, 6))

plt.scatter(dataset_ang45[:,0], dataset_ang45[:,1], color='red', marker='o')

plt.xlabel('X')
plt.ylabel('Y')

plt.xlim(-2, 2)
plt.ylim(-2, 2)

plt.title('Obrót o 45 stopni')
plt.show()
```

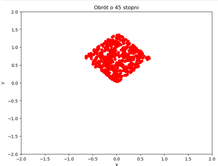

Test funkcji rozciagania - rozciągnięcie względem osi X pięciokrotnie i względem oni Y dwukrotnie

In [24]:
```
str5_2 = stretch(5, 2)
str5_2
```

Out[24]:
```
array([[5, 0],
       [0, 2]])
```

In [25]:
```
dataset_str5_2 = np.dot(dataset, str5_2)
```

In [26]:
```
plt.figure(figsize=(6, 6))

plt.scatter(dataset_str5_2[:,0], dataset_str5_2[:,1], color='red', marker='o')

plt.xlabel('X')
plt.ylabel('Y')

plt.xlim(-2, 6)
plt.ylim(-2, 6)

plt.title('Rozciagnięcie X: * 5, Y: * 2')
plt.show()
```

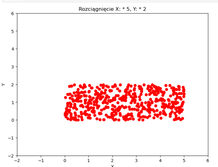

Test funkcji pełnej transformacji obrót o 120 stopni, rozciągnięcie X: * 10, Y * 3

In [31]:
```
dataset_ang120_10_3 = perform_transformation(dataset, 120, 10, 3)

plt.figure(figsize=(6, 6))

plt.scatter(dataset_ang120_10_3[:,0], dataset_ang120_10_3[:,1], color='red', marker='o')

plt.xlabel('X')
plt.ylabel('Y')

plt.xlim(-10, 4)
plt.ylim(-4, 10)

plt.title('Obrót o 120 stopni, rozciagnięcie X: * 5, Y: * 2 przy wykorzystaniu funkcji transformacji')
plt.show()
```

Obrót o 120 stopni, rozciagnięcie X: * 5, Y: * 2 przy wykorzystaniu funkcji transformacji

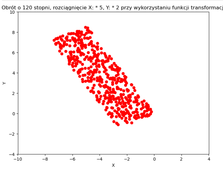

Testy na wygenerowanym zbiorze danych na podstawie wielowymiarowego rozkładu normalnego

In [33]:
```
dataset = np.array(generate_dataset_norm(500))
```

In [38]:
```
plt.figure(figsize=(6, 6))

plt.scatter(dataset[:,0], dataset[:,1], color='red', marker='o')

plt.xlabel('X')
plt.ylabel('Y')

plt.xlim(-3, 3)
plt.ylim(-3, 3)

plt.title('Wygenerowany zbiór')
plt.show()
```

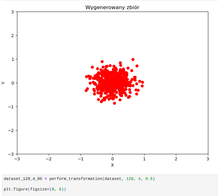

In [40]:
```
dataset_120_4_05 = perform_transformation(dataset, 120, 4, 0.5)

plt.figure(figsize=(6, 6))

plt.scatter(dataset_120_4_05[:,0], dataset_120_4_05[:,1], color='red', marker='o')

plt.xlabel('X')
plt.ylabel('Y')

plt.xlim(-7, 7)
plt.ylim(-7, 7)

plt.title('Obrót o 120 stopni, rozciagnięcie X: * 4, Y: * 0.5')
plt.show()
```

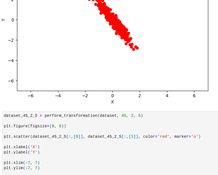

In [45]:
```
dataset_45_2_5 = perform_transformation(dataset, 45, 2, 5)

plt.figure(figsize=(6, 6))

plt.scatter(dataset_45_2_5[:,0], dataset_45_2_5[:,1], color='red', marker='o')

plt.xlabel('X')
plt.ylabel('Y')

plt.xlim(-7, 7)
plt.ylim(-7, 7)

plt.title('Obrót o 45 stopni, rozciagnięcie X: * 2, Y: * 5')
plt.show()
```

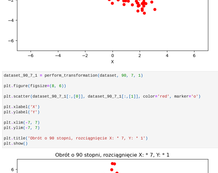

In [50]:
```
dataset_90_7_1 = perform_transformation(dataset, 90, 7, 1)

plt.figure(figsize=(6, 6))

plt.scatter(dataset_90_7_1[:,0], dataset_90_7_1[:,1], color='red', marker='o')

plt.xlabel('X')
plt.ylabel('Y')

plt.xlim(-7, 7)
plt.ylim(-7, 7)

plt.title('Obrót o 90 stopni, rozciagnięcie X: * 7, Y: * 1')
plt.show()
```

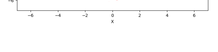

Wnioski

Powyższe testy i zaobserwowane przykłady pokazują poprawność implementacji operacji transformacji (obrót i rozciąganie) zbioru danych.